67-я студенческая научная конференция ЮУрГУ

Реализация теста Graph500 для параллельной СУБД PargreSQL

Сафонов А. Ю. группа ВМИ-456

Научный руководитель:
кандидат физ.-мат. наук Цымблер М. Л.

www.graph500.org/results_nov_2013?order=field_submission_gigateps_value&sort=desc

The Graph 500 List

Top 10
(November 2013)

Rank	Machine
1	DOE/NNSA/LLNL Sequoia - Lawrence Livermore National Laboratory (65536 nodes, 1048576 cores)
2	DOE/SC/Argonne National Laboratory Mira - Argonne National Laboratory (49152 nodes, 786432 cores)
3	JUQUEEN - Forschungszentrum Juelich (FZJ) (16384 nodes, 262144 cores)
4	K computer - RIKEN Advanced Institute for Computational Science (AICS) (65536 nodes, 524288 cores)
5	Fermi - CINECA (8192 nodes, 131072 cores)
	Tianhe-2

November 2013

No.	Rank	Machine	Installation Site	Number of nodes	Number of cores	Problem scale	GTEPS
1	1	DOE/NNSA/LLNL Sequoia (IBM - BlueGene/Q, Power BQC 16C 1.60 GHz)	Lawrence Livermore National Laboratory	65536	1048576	40	15363
2	2	DOE/SC/Argonne National Laboratory Mira (IBM - BlueGene/Q, Power BQC 16C 1.60 GHz)	Argonne National Laboratory	49152	786432	40	14328
3	3	JUQUEEN (IBM - BlueGene/Q, Power BQC 16C 1.60 GHz)	Forschungszentrum Juelich (FZJ)	16384	262144	38	5848
4	4	K computer (Fujitsu - Custom supercomputer)	RIKEN Advanced Institute for Computational Science (AICS)	65536	524288	40	5524.12
5	5	Fermi (IBM - BlueGene/Q, Power BQC 16C 1.60 GHz)	CINECA	8192	131072	37	2567
6	6	Tianhe-2 (MilkyWay-2) (National University of Defense Technology - MPP)	Changsha, China	8192	196608	36	2061.48
		Turing (IBM -					

Цель и задачи исследования

- Цель
- Оценка эффективности параллельной СУБД PargreSQL на задачах интенсивной обработки данных с помощью сравнительного теста Graph500
- Задачи
- Изучить архитектуру параллельной СУБД PargreSQL и спецификацию теста Graph500
- Разработать схему базы данных для хранения графа и промежуточных данных в соответствии со спецификацией теста Graph500
- Выполнить проектирование и разработку алгоритмов на языке SQL, реализующих тест Graph500 для параллельной СУБД PargreSQL
- Провести вычислительные эксперименты на суперкомпьютере “Торнадо ЮурГУ”, исследующие эффективность параллельной СУБД PargreSQL на тесте Graph500

Параллельная СУБД PargreSQL

- Фрагментный паралеллизм

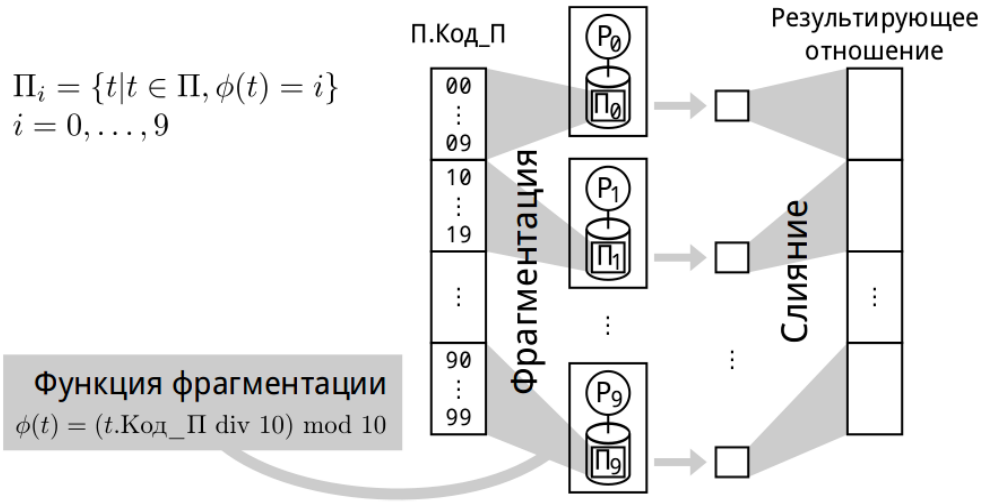

- Архитектура PargreSQL

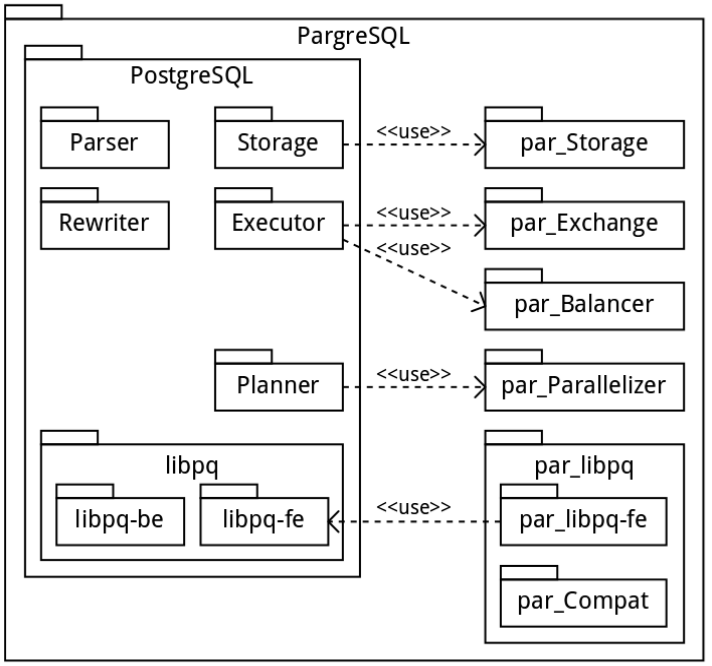

Тест Graph500

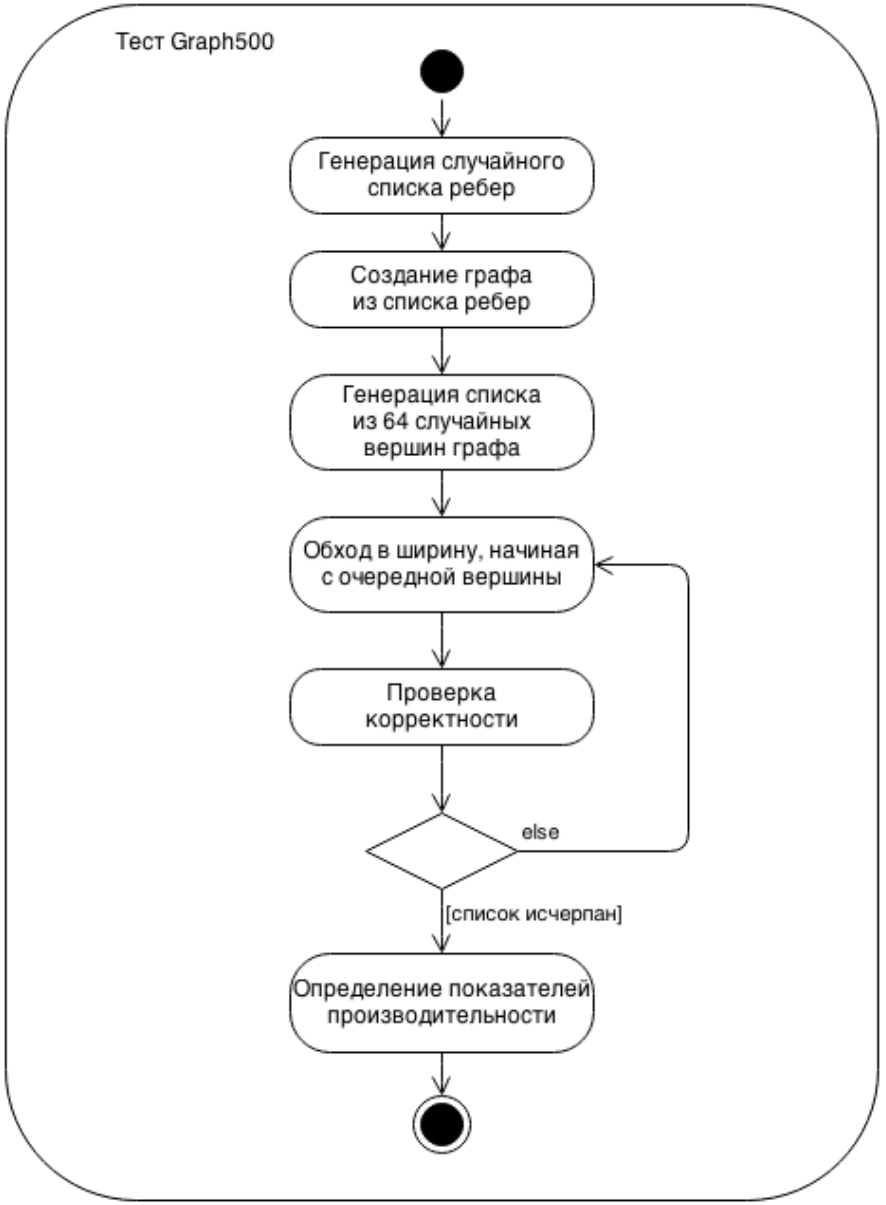

Тест Graph500

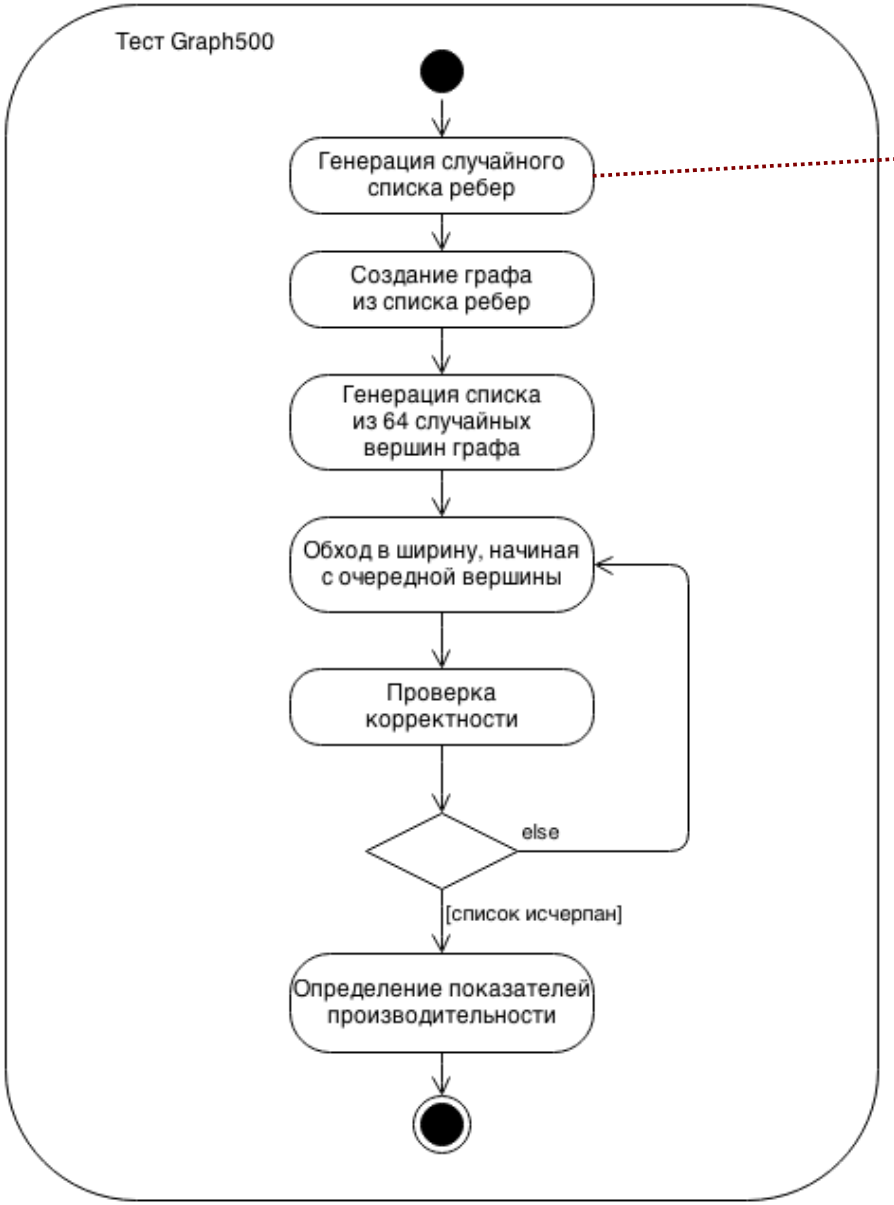

Начальная вершина	Конечная вершина
0	1
2	0
1	2
3	1
4	2
4	1
2	5
3	2

Класс задачи	Количество вершин	Количество ребер	Память
Игрушечный (уровень 10)	2^{26}	2^{30}	17 ГБ
Минимальный (уровень 11)	2^{29}	2^{33}	137 ГБ
Маленький (уровень 12)	2^{32}	2^{36}	1 ТБ
Средний (уровень 13)	2^{36}	2^{40}	17 ТБ
Большой (уровень 14)	2^{39}	2^{43}	140 ТБ
Огромный (уровень 15)	2^{42}	2^{46}	1 ПБ

Тест Graph500

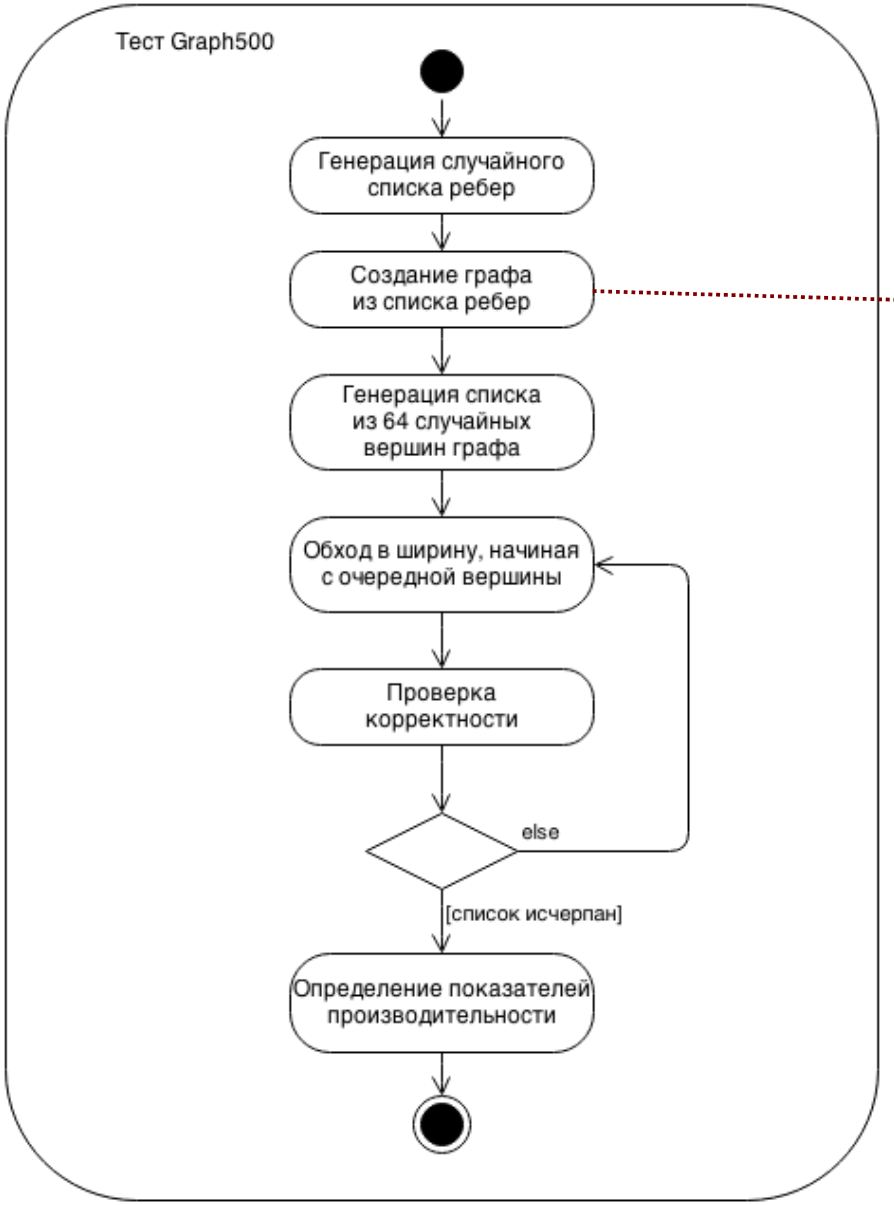

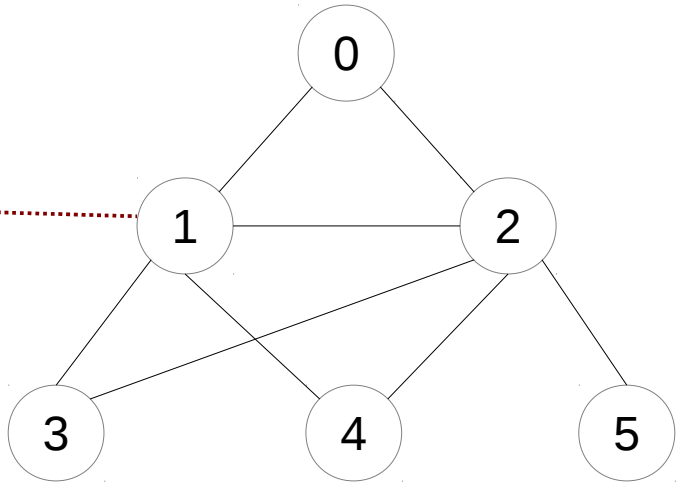

Тест Graph500

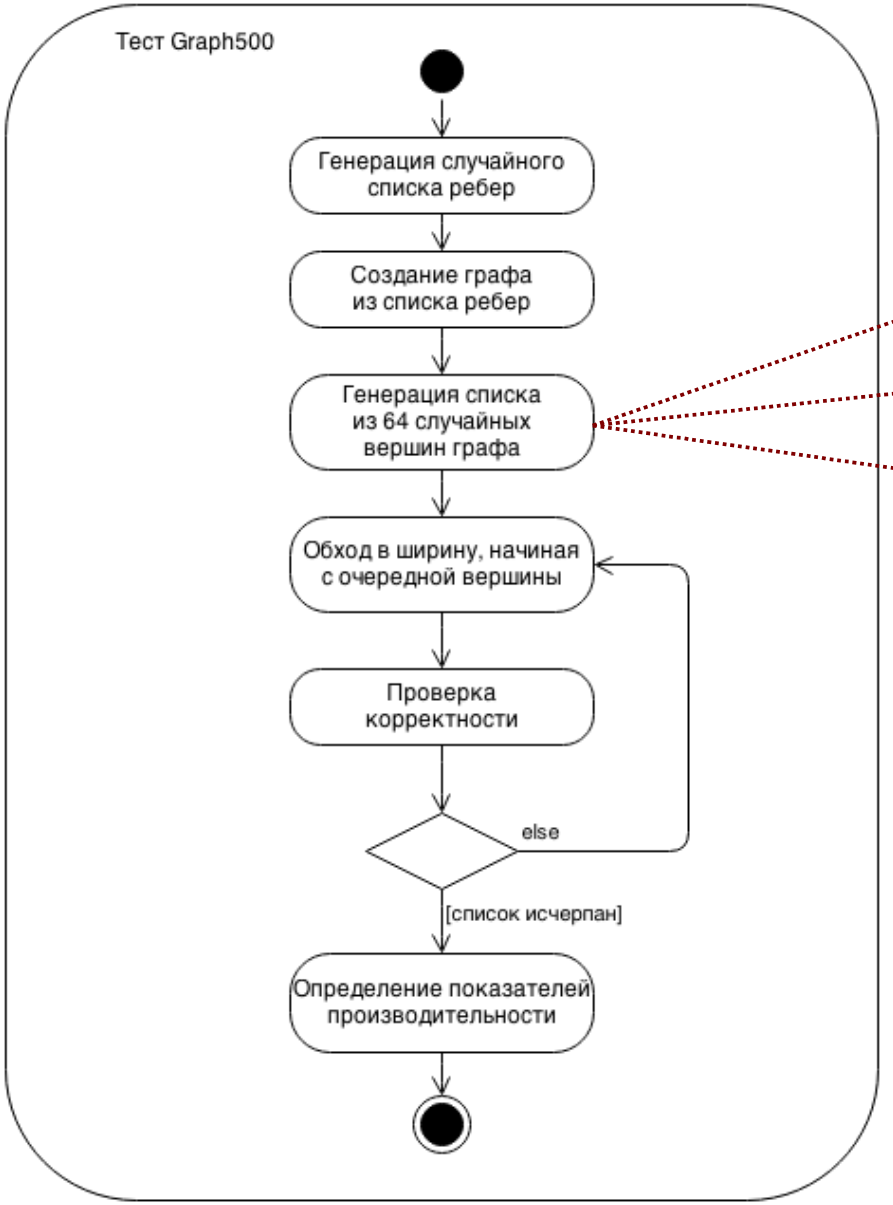

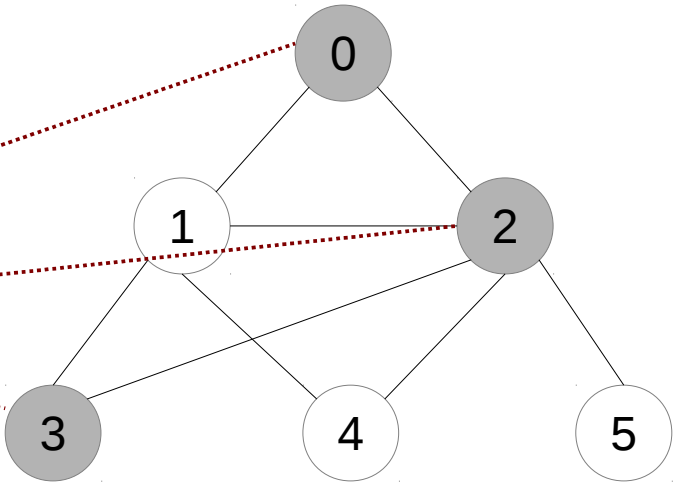

Тест Graph500

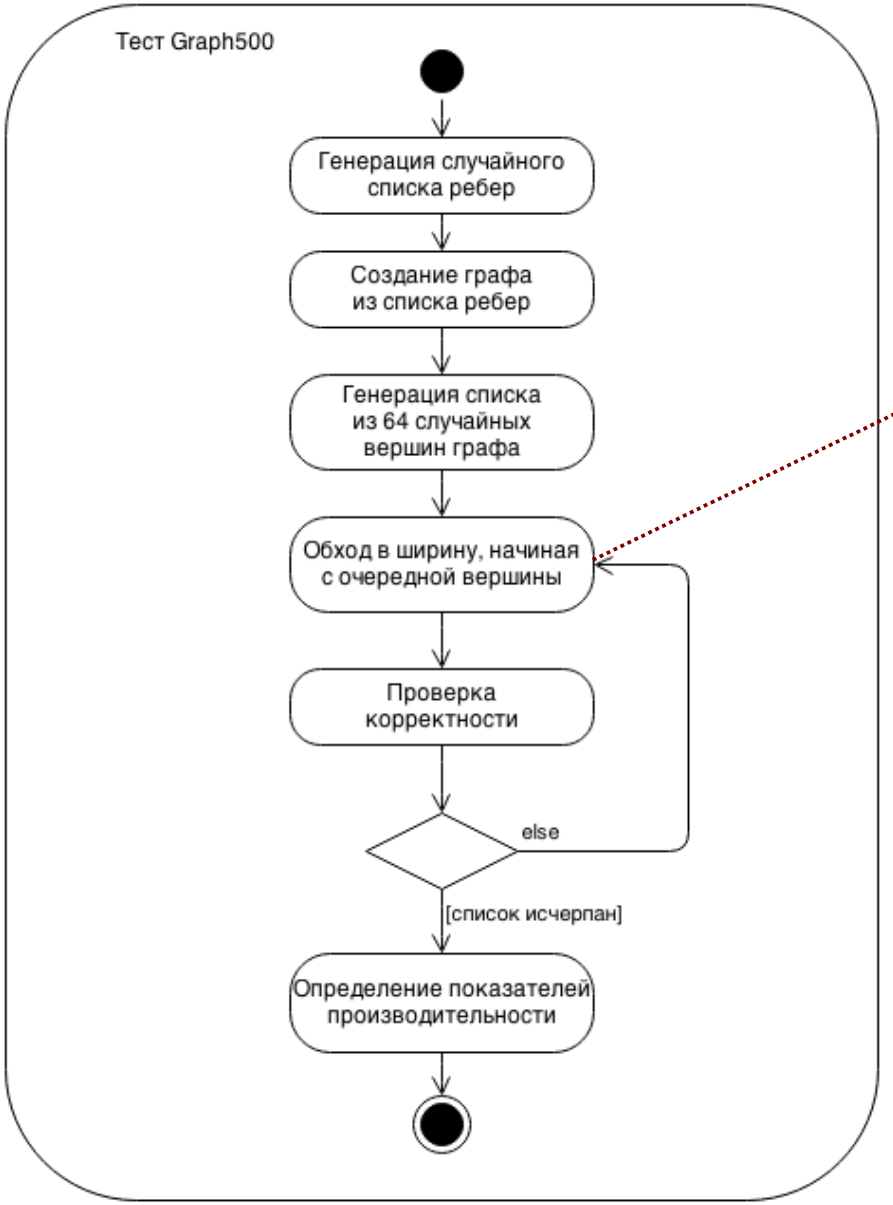

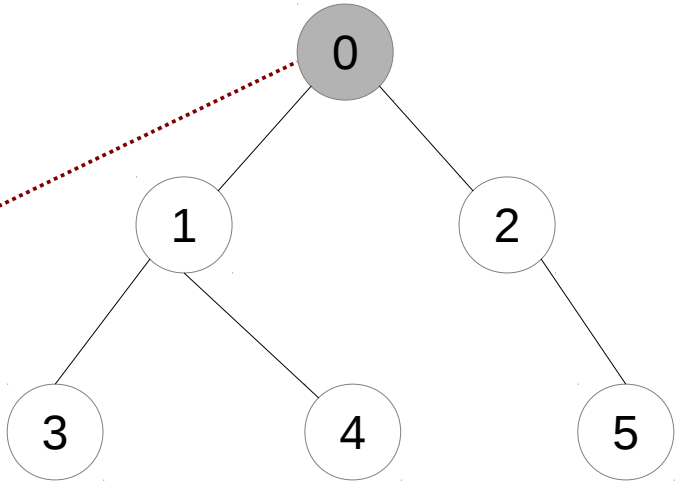

Тест Graph500

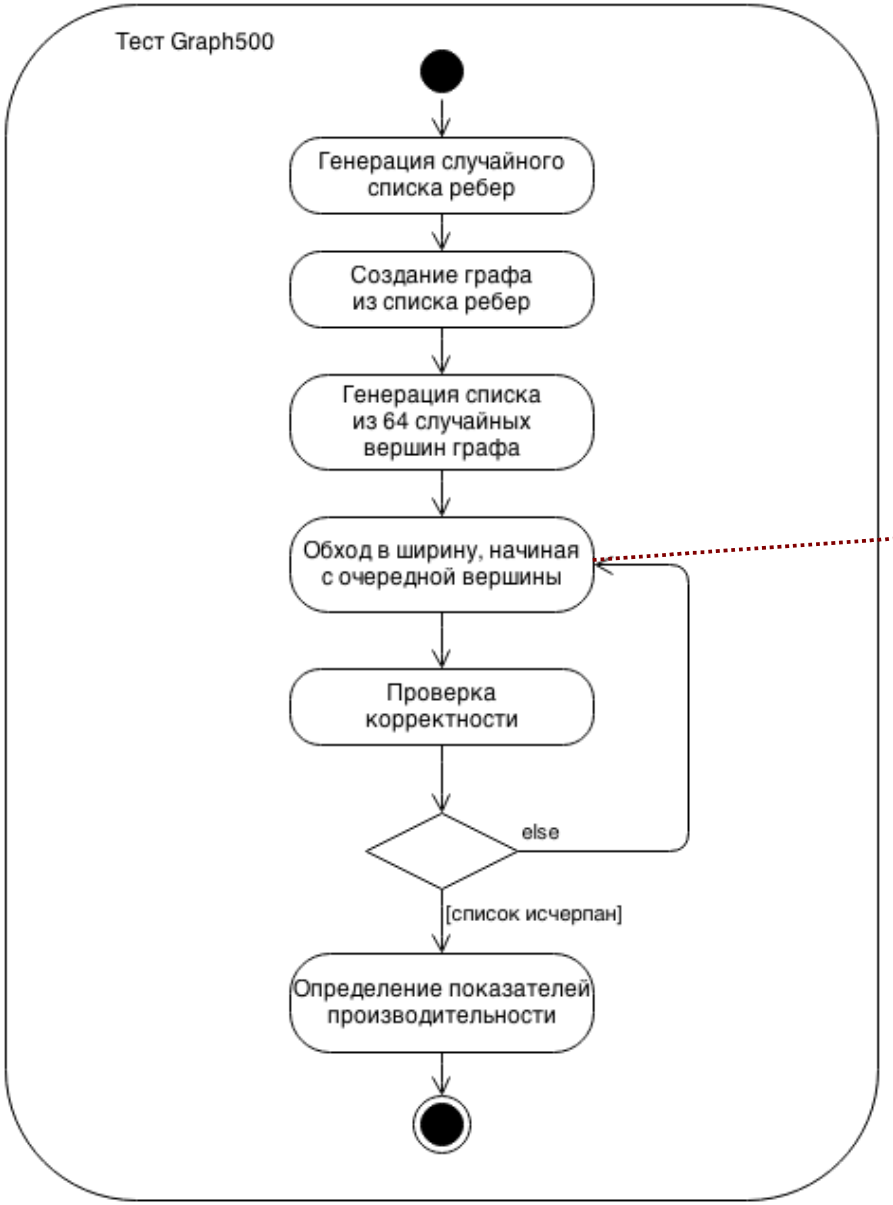

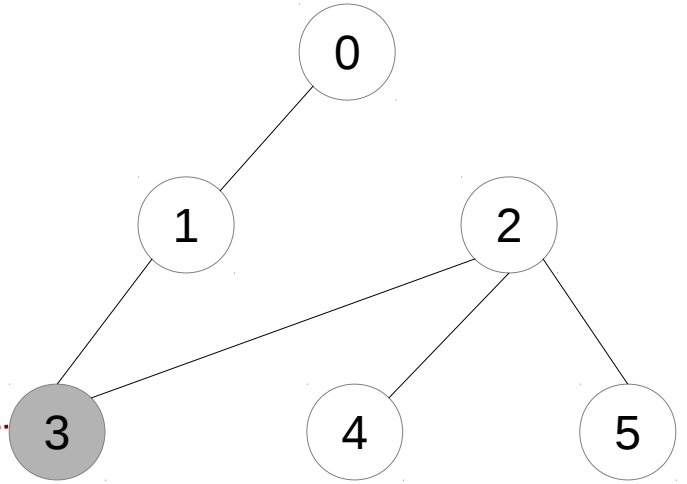

Тест Graph500

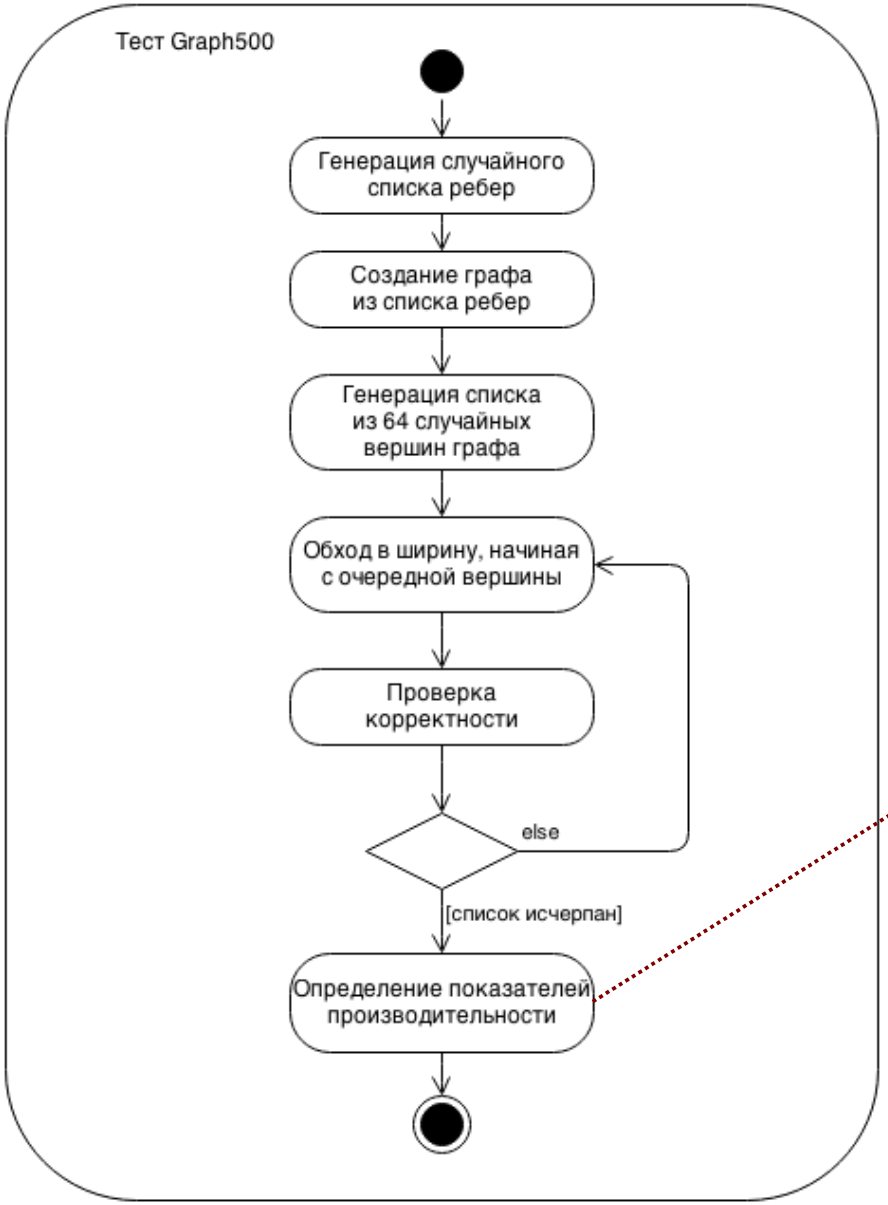

Производительность:
412 GTEPS

Обход в ширину

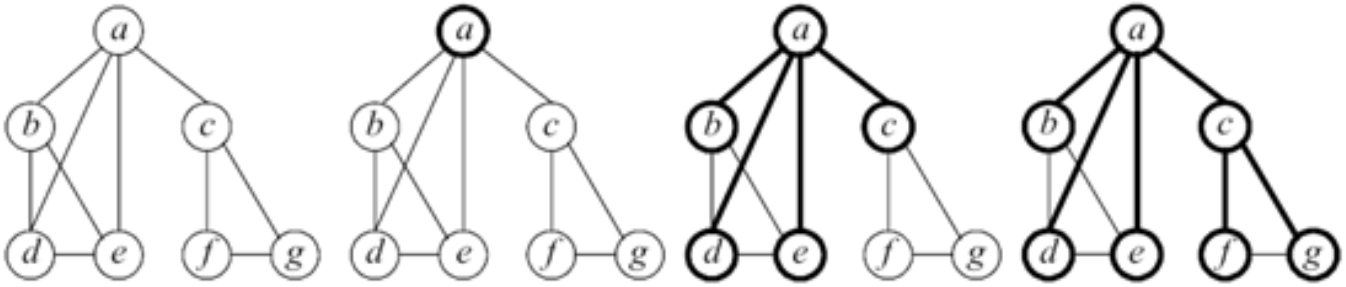


```
BFS (start_node) {
    for (all nodes i) {
        parent[i] = -1;
    }

    queue.push(start_node);
    parent[start_node] = start_node;

    while( !queue.empty() ) {
        node = queue.pop();
        foreach(child in expand(node)) {
            if(parent[child] == -1) {
                queue.push(child);
                parent[child] = node;
            }
        }
    }
}
```

Схема данных

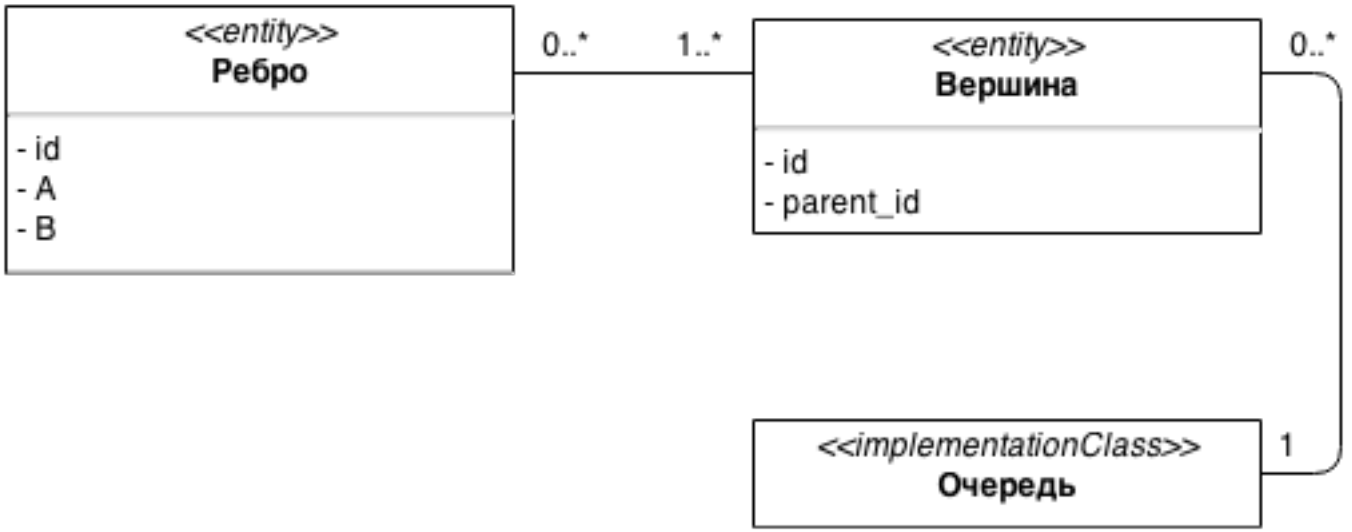

Таблица хранения

```
create table edge (
    id bigserial primary key,    -- порядковый номер ребра
    a bigint,                    -- первая вершина ребра
    b bigint,                    -- вторая вершина ребра
    parent bigint,               -- родитель вершины
    queue bigint                 -- номер вершины в очереди
)
```

Функция фрагментации = id % [Количество узлов]

Реализация поиска в ширину с использованием API PargreSQL

```
BFS (start_node) {
    for (all nodes i) {
        parent[i] = -1;
    }

    queue.push(start_node);
    parent[start_node] = start_node;

    while( !queue.empty() ) {
        node = queue.pop();
        foreach(child in expand(node)) {
            if(parent[child] == -1) {
                queue.push(child);
                parent[child] = node;
            }
        }
    }
}
```

```
#include <par_libpq-fe.h>

int main () {
    conn = PQconnectdb(
        "dbname=alexander host=localhost user=alexander password=*****");

    long long lastQueueNumber = 0;  // номер последнего добавленного элемента
    long long currentQueueNumber = 0;   // номер текущего элемента

    PQexec(conn,"update edge set parent=-1, queue=NULL");
    PQexec(conn,"update edge set parent=%ld, queue=%ld where a=%ld",
        startNode,lastQueueNumber,startNode);

    while (currentQueueNumber <= lastQueueNumber) {
        children = PQexec(conn,
            "select distinct a,b from edge where queue=%ld",
            currentQueueNumber);
        long long childCount = PQntuples(children);
        long long node = PQgetvalue(children, 0, A_COLUMN));
        for (long long i = 0; i < childCount; ++i)
        {
            long long child = PQgetvalue(children, i, B_COLUMN));
            long long parent = PQexec(conn,
                "select distinct parent from edge where a=%ld",child);
            if (parent == -1) {     // вершина еще не добавлена в очередь
                ++lastQueueNumber;
                PQexec(conn,
                    "update edge set queue=%ld,parent=%ld WHERE a=%ld"
                    lastQueueNumber,node,child);
            }
        }
        ++currentQueueNumber;
    }
    return 0;
}
```

Проверка корректности

Для каждого ключа поиска после завершения обхода графа в ширину нужно проверить, что соблюдены условия:

1. Полученное BFS-дерево является деревом и не содержит циклов.
2. Каждое ребро BFS-дерева соединяет вершины, чей уровень при обходе в ширину различается ровно на 1.
3. Каждое ребро из входного списка ребер соединяет вершины, уровень которых в BFS-дереве различается не более чем на единицу или же обе эти вершины не включены в BFS-дерево.
4. BFS-дерево связывает все вершины данной компоненты связности.
5. Каждая вершина и ее родитель соединены ребром в исходном графе.

Оценка производительности

TEPS (traversed edges per second) — количество пройденных ребер за секунду:

$$TEPS = m / time_{K2}$$

m — количество ребер в итоговом BFS-дереве
$time_{K2}$ — время работы алгоритма обхода в ширину

Текущие результаты

- Изучена архитектура параллельной СУБД PargreSQL и спецификация теста Graph500
- Разработана схема базы данных для хранения графа и промежуточных данных в соответствии со спецификацией теста Graph500
- Выполнено проектирование и разработка алгоритмов на языке SQL, реализующих тест Graph500 для параллельной СУБД PargreSQL